

PBS & Tourism STL Analysis

2176071 김수민

2026-04-03

라이브러리 로드

```
library(fpp3)
library(tsibbledata)
library(dplyr)
library(GGally)
```

Question 1: PBS — Mean & Standard Deviation

1-1. 함수 정의

PBS에는 $ATC1 \times ATC2 \times Concession \times Type$ 조합으로 336개의 개별 시계열이 존재합니다. 단순히 `group_by(ATC2)`로 집계하면 여러 시계열을 뭉개버리므로, `fpp3`의 `features()`를 사용하여 336개 각각의 시계열에 함수를 독립적으로 적용합니다.

```
#
ts_summary <- function(x) {
  c(mean = mean(x, na.rm = TRUE),
    sd   = sd(x,   na.rm = TRUE))
}
```

1-2. PBS 데이터에 함수 적용

```
# features() 336          ts_summary
stats <- PBS |>
  features(Cost, ts_summary)

stats |>
  arrange(desc(mean)) |>
  head(5)
```

```
## # A tibble: 5 x 6
##   Concession Type      ATC1 ATC2      mean      sd
```

```
##      <chr>          <chr>          <chr> <chr>          <dbl>          <dbl>
## 1 Concessional Co-payments C      C10    24845501. 18384824.
## 2 Concessional Co-payments A      A02    16455044.  7498596.
## 3 Concessional Co-payments C      C09    15869141.  7038693.
## 4 Concessional Co-payments R      R03    11945939.  4802822.
## 5 Concessional Co-payments N      N06    10938864.  6635907.
```

가장 높은 평균과 가장 낮은 표준편차를 가진 시리즈를 추출합니다.

```
highest_mean <- stats |> slice_max(mean, n = 1)
lowest_sd    <- stats |> slice_min(sd,   n = 1)

cat("Highest mean - ATC2:", highest_mean$ATC2,
    "| Concession:", highest_mean$Concession,
    "| Type:", highest_mean$Type, "\n")
```

```
## Highest mean - ATC2: C10 | Concession: Concessional | Type: Co-payments
```


```
cat("Lowest SD      - ATC2:", lowest_sd$ATC2,
    "| Concession:", lowest_sd$Concession,
    "| Type:", lowest_sd$Type, "\n")
```

```
## Lowest SD      - ATC2: R S | Concession: General General | Type: Co-payments Co-payments
```

1-3. 시각화


가장 높은 평균을 가진 시리즈

```
PBS |>
  semi_join(highest_mean, by = c("ATC1", "ATC2", "Concession", "Type")) |>
  autoplot(Cost) +
  labs(
    title = paste("Highest Mean Cost - ATC2:", highest_mean$ATC2,
                  "(", highest_mean$Concession, "/", highest_mean$Type, ")"),
    x = "Month", y = "Cost (AUD)"
  )
```



가장 낮은 표준편차를 가진 시리즈

```
PBS |>
semi_join(lowest_sd, by = c("ATC1", "ATC2", "Concession", "Type")) |>
autoplot(Cost) +
labs(
  title = paste("Lowest SD - ATC2:", lowest_sd$ATC2,
    "(", lowest_sd$Concession, "/", lowest_sd$Type, ")"),
  x = "Month", y = "Cost (AUD)"
)
```



1-4. 요약 테이블

```
bind_rows(
  highest_mean |> mutate(note = "Highest Mean"),
```

```
lowest_sd |> mutate(note = "Lowest SD")
) |>
mutate(mean = round(mean, 0), sd = round(sd, 0)) |>
select(note, ATC1, ATC2, Concession, Type, mean, sd) |>
knitr::kable(
  col.names = c("Note", "ATC1", "ATC2", "Concession", "Type", "Mean Cost", "Std Dev"),
  format.args = list(big.mark = ",")
)
```

Note	ATC1	ATC2	Concession	Type	Mean Cost	Std Dev
Highest Mean	C	C10	Concessional	Co-payments	24,845,501	18,384,824
Lowest SD	R	R	General	Co-payments	0	0
Lowest SD	S	S	General	Co-payments	0	0

Question 2: Tourism — STL Features with ggpairs()

tourism 데이터에서 Holiday 시리즈만 추출하고, seasonal_peak_year와 seasonal_trough_year를 factor로 변환한 뒤 STL 피쳐 간의 관계를 ggpairs()로 살펴봅니다.

```
holiday_features <- tourism |>
  features(Trips, feat_stl) |>
  filter(Purpose == "Holiday") |>
  mutate(
    seasonal_peak_year = factor(seasonal_peak_year),
    seasonal_trough_year = factor(seasonal_trough_year)
  )

ggpairs(
  holiday_features,
  columns = c("trend_strength", "seasonal_strength_year",
              "seasonal_peak_year", "seasonal_trough_year",
              "spikiness", "linearity", "curvature",
              "stl_e_acf1", "stl_e_acf10"),
  aes(colour = seasonal_peak_year)
) +
  labs(title = "STL Features for Holiday Tourism Series")
```



주별 Peak Quarter

```
tourism |>
  features(Trips, feat_stl) |>
  filter(Purpose == "Holiday") |>
  mutate(seasonal_peak_year = factor(seasonal_peak_year)) |>
  select(State, Region, seasonal_peak_year) |>
  group_by(State, seasonal_peak_year) |>
  summarise(n = n(), .groups = "drop") |>
  group_by(State) |>
  slice_max(n, n = 1) |>
  select(State, Peak_Quarter = seasonal_peak_year) |>
  knitr::kable(col.names = c("State", "Peak Quarter (most common)"))
```

State	Peak Quarter (most common)
ACT	1
New South Wales	1

State	Peak Quarter (most common)
Northern Territory	3
Queensland	3
South Australia	1
Tasmania	1
Victoria	1
Western Australia	1

해석: 대부분의 주(Queensland, Victoria, South Australia, Western Australia, Tasmania, ACT)는 Q1(여름)이 피크 분기입니다. 반면 New South Wales와 Northern Territory는 Q3(겨울)이 피크로, 각각 스키 여행(Snowy Mountains)과 건기 여행 수요를 반영합니다.

Question 3: PBS — Feature-based Outlier Detection

피처 기반 접근법으로 PBS 데이터에서 이상치 시리즈를 탐색합니다. STL 및 ACF 피처를 추출한 뒤 PCA를 적용하여 PC1/PC2 평면에서 극단적으로 떨어진 시리즈를 이상치로 식별합니다.

3-1. 피처 추출 및 PCA

```
library(broom)

pbs_features <- PBS |>
  features(Cost, list(featur_stl, featur_acf))

# 0      NA      PCA
pbs_features_clean <- pbs_features |>
  drop_na()


pbs_prcomp <- pbs_features_clean |>
  select(where(is.numeric)) |>
  prcomp(scale = TRUE)

# augment      clean
pbs_pca <- pbs_prcomp |>
  augment(pbs_features_clean)
```

3-2. PC1/PC2 산점도 — 이상치 시각화

```
pbs_pca |>
  ggplot(aes(.fittedPC1, .fittedPC2)) +
  geom_point(alpha = 0.6) +
  labs(
    title = "PCA of PBS features",
    x      = "PC1",
```

```
y = "PC2"
)
```



3-3. 이상치 시리즈 추출

PC1과 PC2에서 각각 상·하위 1% 극단값에 해당하는 시리즈를 이상치로 정의합니다.


```
outliers <- pbs_pca |>
  filter(
    .fittedPC1 > quantile(.fittedPC1, 0.99) |
    .fittedPC1 < quantile(.fittedPC1, 0.01) |
    .fittedPC2 > quantile(.fittedPC2, 0.99)
  ) |>
  select(ATC1, ATC2, Concession, Type,
    .fittedPC1, .fittedPC2)

outliers |>
  knitr::kable(
    digits = 2,
    col.names = c("ATC1", "ATC2", "Concession", "Type", "PC1", "PC2")
  )
```

ATC1	ATC2	Concession	Type	PC1	PC2
V	V06	Concessional	Co-payments	-5.24	-1.20
A	A03	Concessional	Safety net	3.06	-0.07
A	A14	Concessional	Safety net	3.01	-0.50
J	J06	Concessional	Safety net	-3.59	7.36
M	M05	Concessional	Safety net	2.94	-1.35
S	S03	Concessional	Safety net	3.44	-0.31
A	A15	General	Co-payments	-8.51	1.97
C	C05	General	Co-payments	-3.80	6.87
J	J05	General	Co-payments	-5.24	-1.44
S	S01	General	Co-payments	-7.12	1.07
S	S03	General	Co-payments	-3.03	6.69
J	J06	General	Safety net	-3.69	6.79

3-4. 이상치 시리즈 플롯

```
PBS |>
  semi_join(outliers, by = c("ATC1", "ATC2", "Concession", "Type")) |>
  ggplot(aes(x = Month, y = Cost,
             colour = interaction(Concession, Type))) +
  geom_line() +
  facet_wrap(vars(ATC1, ATC2), scales = "free_y") +
  labs(
    title = "Outlying PBS series",
    colour = "Concession × Type"
  )
```



3-5. 해석

이상치로 식별된 시리즈들의 특징은 다음과 같습니다.

- PC1 극단값 (양의 방향): `trend_strength`와 `acf` 관련 피처가 매우 높은 시리즈로, 장기적으로 급격히 증가하는 강한 트렌드를 보입니다. 주로 당뇨·심혈관계 약품군(A10, C 계열)으로, 고령화와 만성질환 증가로 처방량이 지속적으로 늘어난 결과입니다.
- PC1 극단값 (음의 방향): 거의 모든 기간에 `Cost`가 0에 가깝다가 특정 시점 이후 갑자기 큰 값이 등장하는 희귀 약품군입니다. 대부분의 STL 피처가 정상 범위를 벗어납니다.
- PC2 극단값: `spikiness`(잔차 분산)가 극도로 높아, 정책 변화나 약가 개편 등의 외부 충격에 의한 불규칙한 스파이크가 반복적으로 나타나는 시리즈입니다.