

Forecasting: Principles and Practice - Chapter 5 Exercises

5.11 Exercise 1, 3, 5, 7, 9, 11

2176071 김수민

2026-04-01

```
library(fpp3)
```


Exercise 1

각 시계열의 특성에 맞는 벤치마크 방법을 골라 예측을 수행했다. 기준은 계절성 유무와 추세 존재 여부다. 계절성이 뚜렷하면 SNAIVE(), 추세만 있고 계절성이 없으면 RW(drift), 둘 다 없으면 NAIVE()를 사용했다.

호주 인구 (Australian Population)

인구 데이터는 연간 데이터라 계절성이 없고, 꾸준히 오르는 추세만 있다. RW(drift)가 적합하다.


```
global_economy |>
  filter(Country == "Australia") |>
  model(RW(Population ~ drift())) |>
  forecast(h = 10) |>
  autoplot(global_economy |> filter(Country == "Australia")) +
  labs(
    title = "Australian Population - RW with Drift",
    y = "Population"
  )
```



벽돌 생산량 (Bricks)

분기별 데이터로 계절 패턴이 있어 SNAIVE()를 썼다.


```
aus_production |>
  filter(!is.na(Bricks)) |>
  model(SNAIVE(Bricks)) |>
  forecast(h = 8) |>
  autoplot(aus_production |> filter(!is.na(Bricks))) +
  labs(
    title = "Bricks Production - Seasonal Naïve",
    y = "Bricks (million)"
  )
```



NSW 양 (NSW Lambs)

월별 가축 데이터라 계절성이 있다. SNAIVE()를 적용했다.


```
aus_livestock |>
  filter(State == "New South Wales", Animal == "Lambs") |>
  model(SNAIVE(Count)) |>
  forecast(h = 12) |>
  autoplot(aus_livestock |> filter(State == "New South Wales", Animal == "Lambs")) +
  labs(
    title = "NSW Lambs - Seasonal Naïve",
    y = "Count (thousands)"
  )
```



가계 자산 (Household Wealth)

연간 데이터라 계절성이 없고 추세가 있다. $RW(drift)$ 를 사용했다.


```
hh_budget |>
  model(RW(Wealth ~ drift())) |>
  forecast(h = 5) |>
  autoplot(hh_budget) +
  labs(
    title = "Household Wealth - RW with Drift",
    y = "Wealth"
  )
```



호주 테이크아웃 음식 매출 (Takeaway Food Turnover)

월별 데이터로 계절성이 분명히 있다. SNAIVE()를 사용했다.

```
aus_retail |>
  filter(Industry == "Takeaway food services") |>
  summarise(Turnover = sum(Turnover)) |>
  model(SNAIVE(Turnover)) |>
  forecast(h = 24) |>
  autoplot(
    aus_retail |>
      filter(Industry == "Takeaway food services") |>
      summarise(Turnover = sum(Turnover))
  ) +
  labs(
    title = "Takeaway Food Turnover - Seasonal Naïve",
    y = "Turnover ($M)"
  )
```



Exercise 3


1992년 이후 분기별 호주 맥주 생산량에 SNAIVE()를 적합하고 잔차를 진단했다.

```
recent_production <- aus_production |>  
  filter(year(Quarter) >= 1992)
```

```
fit3 <- recent_production |>  
  model(SNAIVE(Beer))
```


```
fit3 |> gg_tsresiduals() +  
  labs(title = "Residual Diagnostics - Beer Production SNAIVE")
```

Residual Diagnostics – Beer Production SNAIVE



```
fit3 |>
  forecast() |>
  autoplot(recent_production) +
  labs(
    title = "Beer Production Forecast - Seasonal Naïve (1992~)",
    y = "Beer (megalitres)"
  )
```

Beer Production Forecast – Seasonal Naïve (1992~)



```
augment(fit3) |>
  features(.innov, ljung_box, lag = 8, dof = 0)
```

```
## # A tibble: 1 x 3
##   .model      lb_stat lb_pvalue
##   <chr>      <dbl>    <dbl>
## 1 SNAIVE(Beer) 32.3 0.0000834
```

잔차 그림을 보면 ACF에서 lag 4 근처에 유의한 스파이크가 하나 보인다. 히스토그램은 대략 정규분포 형태이긴 한데, Ljung-Box 검정 결과 p-value가 0.05보다 작게 나왔다. 즉 잔차에 자기상관이 일부 남아있어서 완전한 백색잡음이라고 보기는 어렵다. SNAIVE()가 계절성은 잘 잡지만 추가적인 패턴은 아직 남아있다는 뜻이다.

Exercise 5

빅토리아주 가축 7종에 SNAIVE()를 일괄 적합하고 예측을 시각화했다.

```
vic_livestock <- aus_livestock |>
  filter(State == "Victoria")

vic_livestock |>
  model(SNAIVE(Count)) |>
  forecast(h = 16) |>
  autoplot(vic_livestock) +
  facet_wrap(~Animal, scales = "free_y", ncol = 2) +
  labs(
```




```

title = "Victorian Livestock - Seasonal Naïve Forecasts",
y = "Count (thousands)"
) +
theme(legend.position = "none")

```

Victorian Livestock – Seasonal Naïve Forecasts



동물 종류마다 계절 패턴의 강도가 꽤 다르다. 양(Lambs, Sheep)처럼 계절성이 뚜렷한 시리즈에서는 SNAIVE()가 나름 합리적인 벤치마크가 된다. 반면 소(Cattle)처럼 추세 변동이 크거나 패턴이 불규칙한 시리즈에서는 단순히 지난해 같은 분기를 반복하는 방식이 체계적인 오차를 낼 수 있어서 벤치마크로서

한계가 있다.

Exercise 7

2장 7번 과제에서 선택한 소매 시계열에 SNAIVE()를 적합하고 예측 정확도를 평가했다.

```
set.seed(2176071)

myseries <- aus_retail |>
  filter(`Series ID` == sample(aus_retail$`Series ID`, 1))

myseries |> distinct(`Series ID`, State, Industry)

## # A tibble: 1 x 3
##   `Series ID` State      Industry
##   <chr>      <chr>      <chr>
## 1 A3349779F Northern Territory Takeaway food services
```


(a) 훈련셋 생성

```
myseries_train <- myseries |>
  filter(year(Month) < 2011)
```

(b) 분할 확인

```
autoplot(myseries, Turnover) +
  autolayer(myseries_train, Turnover, colour = "red") +
  labs(
    title = "Training set (red) vs Full series",
    y = "Turnover ($M)"
  )
```

Training set (red) vs Full series



2011년 이전 데이터가 빨간색으로, 이후가 파란색으로 잘 나뉜 것을 확인할 수 있다.


(c) SNAIVE 적합

```
fit7 <- myseries_train |>
  model(SNAIVE(Turnover))
```

(d) 잔차 진단

```
fit7 |> gg_tsresiduals() +
  labs(title = "Residual Diagnostics - SNAIVE")
```

Residual Diagnostics – SNAIVE



```
augment(fit7) |>
  features(.innov, ljung_box, lag = 24, dof = 0)
```

```
## # A tibble: 1 x 5
##   State      Industry      .model      lb_stat lb_pvalue
##   <chr>      <chr>      <chr>      <dbl>   <dbl>
## 1 Northern Territory Takeaway food services SNAIVE(Turnover)      814.         0
```


잔차 시계열을 보면 분산이 시간이 갈수록 점점 커지는 경향이 있다(이분산). ACF에서도 여러 lag에서 유의한 자기상관이 남아 있다. 이 데이터는 추세가 강해서 SNAIVE()만으로는 그 부분을 잡지 못하고 잔차에 패턴이 남는 것으로 보인다. Ljung-Box p-value도 매우 작게 나와서 잔차가 백색잡음이라고 보기 어렵다. 정규성은 대략 만족하는 편이다.

(e) 테스트 기간 예측

```
fc7 <- fit7 |>
  forecast(new_data = anti_join(myseries, myseries_train))

fc7 |>
  autoplot(myseries) +
  labs(
    title = "SNAIVE Forecast vs Actual (test period)",
```

```
y = "Turnover ($M)"
)
```



(f) 정확도 비교

```
cat("      \n")
```

```
##
```

```
fit7 |> accuracy()
```

```
## # A tibble: 1 x 12
##   State   Industry .model .type    ME  RMSE  MAE  MPE  MAPE  MASE  RMSSE  ACF1
##   <chr>   <chr>   <chr> <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Norther~ Takeawa~ SNAIV~ Trai~ 0.581 1.74 1.15 4.62 13.5    1    1 0.837
```

```
cat("\n      \n")
```

```
##
```

```
##
```

```
fc7 |> accuracy(myseries)
```

```
## # A tibble: 1 x 12
##   .model   State Industry .type    ME  RMSE  MAE  MPE  MAPE  MASE  RMSSE  ACF1
##   <chr>   <chr> <chr>   <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 SNAIVE(T~ Nort~ Takeawa~ Test  2.90 4.19 3.37 12.9 16.0 2.94 2.40 0.866
```

테스트셋 RMSSE가 1보다 상당히 크게 나왔다. 이는 SNAIVE() 자체의 계절 naïve 오차보다도 실제 예측 오차가 더 크다는 뜻으로, 추세 성분 때문에 먼 미래로 갈수록 오차가 급격히 쌓이는 것으로 해석할 수 있다.

(g) 훈련 데이터 양에 따른 민감도

```
cutoffs <- c(2005, 2007, 2009, 2011)

sensitivity <- purrr::map_dfr(cutoffs, function(yr) {
  train <- myseries |> filter(year(Month) < yr)
  test <- myseries |> filter(year(Month) >= yr)

  fc <- train |>
    model(SNAIVE(Turnover)) |>
    forecast(new_data = test)

  acc <- fc |> accuracy(myseries)

  tibble(cutoff = yr, RMSSE = acc$RMSSE, MASE = acc$MASE)
})

print(sensitivity)
```

```
## # A tibble: 4 x 3
##   cutoff RMSSE MASE
##   <dbl> <dbl> <dbl>
## 1  2005  8.34  9.10
## 2  2007  9.66 11.2
## 3  2009  7.95 10.3
## 4  2011  2.40  2.94
```

훈련 종료 시점을 바꿔봤더니 2005년처럼 훈련 기간이 짧을수록 오차가 더 크고, 2011년에 가까울수록 약간 줄어드는 경향이 있다. 다만 이 데이터는 추세가 강하다 보니 어떤 훈련셋을 써도 SNAIVE()의 오차가 전반적으로 크다. 정확도 지표가 훈련 데이터 크기에 다소 민감하게 반응한다.

Exercise 9

가계 자산(hh_budget) 데이터에서 마지막 4년을 테스트셋으로 분리하고 여러 벤치마크를 비교했다.

(a) 훈련/테스트 분리

```
hh_train <- hh_budget |>
  filter(Year <= max(Year) - 4)


hh_test <- hh_budget |>
  filter(Year > max(Year) - 4)
```

(b) 벤치마크 적합

연간 데이터라 계절성이 없어서 MEAN(), NAIVE(), RW(drift)를 비교했다.

```
fit9 <- hh_train |>
  model(
    Mean = MEAN(Wealth),
    Naive = NAIVE(Wealth),
    Drift = RW(Wealth ~ drift())
  )

fit9 |>
  forecast(h = 4) |>
  autoplot(hh_budget, level = NULL) +
  labs(
    title = "Household Wealth - Benchmark Comparison",
    y = "Wealth"
  )
```



(c) 정확도 비교

```
fit9 |>
  forecast(h = 4) |>
  accuracy(hh_budget)
```


```
## # A tibble: 12 x 11
##   .model Country .type ME RMSE MAE MPE MAPE MASE RMSSE ACF1
```

##	<chr>	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
## 1	Drift	Australia	Test	29.1	35.5	29.1	7.23	7.23	1.73	1.48	0.210
## 2	Drift	Canada	Test	33.3	37.2	33.3	6.09	6.09	1.73	1.57	-0.229
## 3	Drift	Japan	Test	14.7	17.9	14.7	2.44	2.44	0.943	0.967	-0.229
## 4	Drift	USA	Test	75.9	76.2	75.9	12.7	12.7	2.88	2.43	-0.561
## 5	Mean	Australia	Test	35.7	42.3	35.7	8.89	8.89	2.12	1.76	0.216
## 6	Mean	Canada	Test	90.4	92.9	90.4	16.7	16.7	4.69	3.92	-0.0799
## 7	Mean	Japan	Test	100.	101.	100.	16.8	16.8	6.45	5.46	-0.534
## 8	Mean	USA	Test	82.9	83.3	82.9	13.9	13.9	3.15	2.65	-0.423
## 9	Naive	Australia	Test	34.7	41.5	34.7	8.64	8.64	2.06	1.73	0.216
## 10	Naive	Canada	Test	46.2	51.0	46.2	8.46	8.46	2.40	2.15	-0.0799
## 11	Naive	Japan	Test	36.3	37.8	36.3	6.06	6.06	2.34	2.04	-0.534
## 12	Naive	USA	Test	82.1	82.5	82.1	13.8	13.8	3.12	2.63	-0.423

세 방법 중 RW(drift)의 RMSSE가 가장 낮게 나왔다. 가게 자산은 꾸준히 오르는 추세가 있어서 추세를 반영하는 drift 방법이 단순 평균이나 naive보다 유리한 것으로 보인다.

(d) 최적 방법 잔차 진단

```
fit9 |>
  filter(Country == "Australia") |>
  select(Drift) |>
  gg_tsresiduals() +
  labs(title = "Residual Diagnostics - RW with Drift (Australia)")
```

```
augment(fit9 |> select(Drift)) |>
  features(.innov, ljung_box, lag = 10, dof = 1)
```

```
## # A tibble: 4 x 4
##   Country .model lb_stat lb_pvalue
##   <chr>    <chr>   <dbl>   <dbl>
## 1 Australia Drift     4.82    0.850
## 2 Canada   Drift     8.87    0.450
## 3 Japan    Drift     6.09    0.730
## 4 USA      Drift    12.9    0.167
```

잔차를 보면 ACF에서 유의한 패턴은 거의 없고, 히스토그램도 대략 종 모양이라 백색잡음에 가깝다. Ljung-Box p-value도 0.05 이상으로 나와서 잔차에 큰 문제는 없는 것으로 판단된다.


Exercise 11

호주 분기별 벽돌 생산량(Bricks, 1956~2005)에 STL 분해를 적용하고 예측을 수행했다.

```
bricks <- aus_production |>
  filter(!is.na(Bricks))
```

(a) STL 분해 — 고정 vs 변화 계절성


```
bricks |>
  model(STL(Bricks ~ trend(window = 13) + season(window = "periodic"))) |>
  components() |>
  autoplot() +
  labs(title = "STL -      (window = 'periodic')")
```



```
bricks |>
  model(STL(Bricks ~ trend(window = 13) + season(window = 7))) |>
  components() |>
  autoplot() +
  labs(title = "STL -      (window = 7)")
```

STL – .. (window = 7)


Bricks = trend + season_year + remainder



고정 계절성과 변화 계절성을 둘 다 해봤는데, 이 데이터에서는 계절 성분이 시간이 지나도 크게 달라지지 않아서 두 결과가 비슷하다. 뒤 과정에서는 고정 계절성을 기준으로 진행했다.

(b) 계절 조정 데이터


```
bricks |>
  model(STL(Bricks ~ season(window = "periodic")))|>
  components() |>
  as_tsibble() |>
  autoplot(season_adjust) +
  labs(
    title = "Seasonally Adjusted Bricks Production",
    y = "Bricks (million)"
  )
```



(c) + (d) decomposition_model로 재계절화 예측

```
fit11 <- bricks |>
  model(
    stl_naive = decomposition_model(
      STL(Bricks ~ season(window = "periodic")),
      NAIVE(season_adjust)
    )
  )


fit11 |>
  forecast(h = 8) |>
  autoplot(bricks) +
  labs(
    title = "Bricks - STL + NAIVE ( )",
    y = "Bricks (million)"
  )
```



(e) 잔차 진단

```
fit11 |> gg_tsresiduals() +  
  labs(title = "Residual Diagnostics - STL + NAIVE")
```

Residual Diagnostics – STL + NAIVE



```
augment(fit11) |>
  features(.innov, ljung_box, lag = 8, dof = 0)
```

```
## # A tibble: 1 x 3
##   .model    lb_stat lb_pvalue
##   <chr>      <dbl>   <dbl>
## 1 stl_naive  15.5    0.0506
```


잔차 ACF를 보면 대부분의 lag에서 유의한 자기상관이 없어서 잔차가 대체로 비상관이라고 볼 수 있다. Ljung-Box p-value도 0.05보다 크게 나왔다.

(f) Robust STL 비교

```
bricks |>
  model(STL(Bricks ~ season(window = "periodic"), robust = TRUE)) |>
  components() |>
  autoplot() +
  labs(title = "Robust STL ")
```


Robust STL ..

Bricks = trend + season_year + remainder



```
fit11_robust <- bricks |>
  model(
    stl_robust = decomposition_model(
      STL(Bricks ~ season(window = "periodic"), robust = TRUE),
      NAIVE(season_adjust)
    )
  )

fit11_robust |>
  forecast(h = 8) |>
  autoplot(bricks) +
  labs(
    title = "Bricks - Robust STL + NAIVE",
    y = "Bricks (million)"
  )
)
```




Robust STL을 써도 예측 결과가 크게 달라지지는 않는다. 이 데이터에 이상치가 두드러지게 많지는 않아서 그런 것 같다.

(g) SNAIVE vs STL+NAIVE — 마지막 2년 테스트

```
bricks_train <- bricks |> slice(1:(n() - 8))

fit_compare <- bricks_train |>
  model(
    SNAIVE = SNAIVE(Bricks),
    STL_NAIVE = decomposition_model(
      STL(Bricks ~ season(window = "periodic")),
      NAIVE(season_adjust)
    )
  )

fit_compare |>
  forecast(h = 8) |>
  autoplot(bricks, level = NULL) +
  labs(
    title = "SNAIVE vs STL+NAIVE - 2",
    y = "Bricks (million)"
  )
```

```
fit_compare |>
  forecast(h = 8) |>
  accuracy(bricks)
```

```
## # A tibble: 2 x 10
##   .model .type ME RMSE MAE MPE MAPE MASE RMSSE ACF1
##   <chr>   <chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 SNAIVE Test  2.75  20   18.2 0.395 4.52 0.504 0.407 -0.0503
## 2 STL_NAIVE Test 8.00  18.1  13.8 1.82  3.36 0.380 0.368 0.0957
```

RMSSE 기준으로 STL+NAIVE가 SNAIVE보다 낮은 오차를 보였다. STL이 추세 성분을 별도로 분리해서 예측하기 때문에 단순히 지난 계절값을 반복하는 SNAIVE보다 유리한 것으로 해석된다.