

HW08 - FPP3 10장 연습문제 (1, 3, 5)

2176071 김수민

2026-05-15

연습문제 1 — Lake Huron 수위 (ARMA 오차를 가진 동적 회귀 모형)

문제: LakeHuron 데이터셋을 이용하여 (a) tsibble로 변환, (b) knot=1920인 구간선형 추세(piecewise linear trend) + ARMA 오차 모형 적합, (c) 이후 30년 예측 수행.

(a) `as_tsibble()` 로 변환

```
# LakeHuron: base R ts object (1875-1972, annual)
lake_tsbl <- as_tsibble(LakeHuron)  # ts 객체를 tsibble로 변환. 시간 인덱스를 자동 인식함


# rename columns
lake_tsbl <- lake_tsbl |>
  rename(Year = index, Level = value)  # as_tsibble() 기능 범용성이 index, value 라서
                                       # 의미 있는 명칭으로 바꿈

head(lake_tsbl)
```

```
## # A tsibble: 6 x 2 [1Y]
##   Year Level
##   <dbl> <dbl>
## 1  1875   580.
## 2  1876   582.
## 3  1877   581.
## 4  1878   581.
## 5  1879   580.
## 6  1880   580.
```

`as_tsibble()` 은 ts 객체의 시간 인덱스를 자동으로 인식하여 tsibble로 변환한다. index는 연도, value는 호수 수위(feet)가 된다.

```
lake_tsbl |>
  autoplot(Level) +
  labs(title = "Lake Huron Level (1875-1972)",
        y = "Level (feet)", x = "Year")
```



(b) 구간선형 추세 (knot=1920) + ARMA 오차

```
# knot at 1920: piecewise linear trend
lake_fit <- lake_tsbl |>
  model(
    ARIMA(Level ~ trend() + I(pmax(Year - 1920, 0)))
  )
report(lake_fit)
```


1920년 이전은 0, 이후는 Year-1920 값을 지정 → I()에서 지정해 주는 구간선형추세
 I()는 4식에서 상수 편상항을 명시
 시간대 따른 선형 추세항 지정. 단항식, 직접 명시하지 않음

```
## Series: Level
## Model: LM w/ ARIMA(2,0,0) errors
##
## Coefficients:
##          ar1          ar2 trend() I(pmax(Year - 1920, 0)) intercept
##          0.9628      -0.3107  -0.0572             0.0633      580.9391
## s.e.    0.0973      0.0983   0.0161             0.0265       0.5124
##
## sigma^2 estimated as 0.4594:  log likelihood=-98.86
## AIC=209.73   AICc=210.65   BIC=225.24
```

ARIMA() 내에 trend()로 전체 선형 추세를, I(pmax(Year - 1920, 0))으로 1920년 이후 기울기 변화방향을 지정한다. ARIMA가 자동으로 ARMA 오차 구조를 선택한다.

추정 결과를 보면 trend() 계수는 -0.057(1920년 이전 연간 감소), I(pmax(Year-1920, 0)) 계수는 +0.063으로, 1920년 이후 순 기울기는 -0.057 + 0.063 = 약 +0.006으로 거의 수평에 가깝다. 즉 1920년 이전에는 수위가 완만히 감소하고, 1920년 이후에는 추세가 수평으로 전환된다.

```
lake_fit |>
  gg_tsresiduals() +
  labs(title = "Residuals: Piecewise Linear + ARMA (Lake Huron)")
```



잔차의 ACF를 보면 대부분의 lag에서 유의수준 내에 있어 ARMA(2,0) 구조가 자기상관을 충분히 흡수하였음을 확인할 수 있다.


(c) 향후 30년 예측

```
# forecast 30 years from 1973: 1973-2002
future_years <- new_data(lake_tsbl, n = 30)
lake_fc <- forecast(lake_fit, new_data = future_years)

lake_fc |>
  autoplot(lake_tsbl) +
  labs(title = "Lake Huron: 30-Year Forecast (Piecewise Linear + ARMA)",
        y = "Level (feet)", x = "Year")
```

이번 데이터에 대해 향후 30년 시계열의 미래 예측은
각종 상황, 외생변수 없는 경우 이것만으로 예측가능

Lake Huron: 30-Year Forecast (Piecewise Linear + ARMA)



외삽 추세의 현실성 평가: 모형에 따르면 1920년 이전에는 수위가 완만히 감소하는 추세이나, 1920년을 기점으로 추세가 거의 수평으로 전환된다. 예측 그래프에서도 이후 30년간(1973-2002) 예측 중앙값이 수평에 가까운 것을 확인할 수 있다. 그러나 호수 수위는 강수량·증발량 등의 기상 요인에 의해 결정되므로, 과거 추세의 단순 외삽은 현실적 신뢰도가 낮다. 예측 구간(prediction interval)도 시간이 지날수록 급격히 넓어지므로 장기 예측의 불확실성이 매우 크다.

연습문제 3 — 일별 전력 수요 (온도 구간선형 knot)

문제: vic_elec 데이터로 일별 전력 수요를 모형화하되, 온도의 이차함수 대신 25°C를 knot으로 하는 구간선형 (piecewise linear) 함수를 사용. 최적 knot 위치를 AICc로 탐색.

데이터 준비

```
vic_elec_daily <- vic_elec |>
  filter(year(Time) == 2014) |> Time 이 date로 형식이라 year() 함수로 연도만 추출해 24 데이터 프레임
  index_by(Date = date(Time)) |> 30분 단위 데이터를 15분으로 집계하기 위해 date(Time)으로 날짜 단위 인덱스 재설정
  summarise(
    Demand      = sum(Demand) / 1e3, 30분 단위 수요를 하루 합산.
    Temperature = max(Temperature), 전력량 MWh → GWh로 변환
    Holiday      = any(Holiday)
  ) |>
  mutate(
    Temp2 = I(pmax(Temperature - 25, 0)), 25(°C) 초과분만 반영하는 구간선형 항. 냉방 수요가 생기기
    Day_Type = case_when(
      Holiday ~ "Holiday", 25°C 이하에서 가계 변화를 모델링
      ~ "Normal"
    )
  )
```

24 시간 단위 (24 = 하루)

```

wday(Date) %in% 2:6 ~ "Weekday",
TRUE ~ "Weekend"
)
)

glimpse(vic_elec_daily)

```

```

## Rows: 365
## Columns: 6
## $ Date      <date> 2014-01-01, 2014-01-02, 2014-01-03, 2014-
01-04, 2014-01-0~
## $ Demand    <dbl> 175.1850, 188.3506, 189.0856, 173.7976, 169.7328, 195.2411
## $ Temperature <dbl> 26.0, 23.0, 22.2, 20.3, 26.1, 19.6, 20.0, 27.4, 32.4, 34.0
## $ Holiday    <lgl> TRUE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE
## $ Temp2      <ldbl> 1, 0, 0, 0, 1.1, 0, 0, 2.4, 7.4, ~
## $ Day_Type   <chr> "Holiday", "Weekday", "Weekday", "Weekend", "Weekend", "W


```

Temp2 = pmax(Temperature - 25, 0): 온도가 25°C 초과일 때만 양수 값을 가지는 추가 기온기
향으로, 냉방 수요 증가를 모형화한다.

```

vic_elec_daily |>
  ggplot(aes(x = Temperature, y = Demand, colour = Day_Type)) +
  geom_point(alpha = 0.5) +
  labs(title = "Daily Electricity Demand vs Temperature (2014)",
       x = "Max Temperature (°C)", y = "Demand (GWh)")

```



모형 적합 (knot = 25°C)

```
elec_fit <- vic_elec_daily |>
  model(
    ARIMA(Demand ~ Temperature + Temp2 + Day_Type + PDQ(0,0,0))
  )
report(elec_fit)
```


Series: Demand
Model: LM w/ ARIMA(3,1,3) errors

Coefficients:
ar1 ar2 ar3 ma1 ma2 ma3 Temperature Temp2
-0.2669 -0.3102 0.5433 0.0251 0.1576 -0.8584 -
0.6116 4.2820
s.e. 0.0955 0.0888 0.0941 0.0624 0.0576 0.0622 0.1946 0.3118
Day_TypeWeekday Day_TypeWeekend
32.2141 -0.7612
s.e. 2.3484 2.3509

sigma^2 estimated as 67.17: log likelihood=-1277.86
AIC=2577.73 AICc=2578.48 BIC=2620.59

Temperature 계수(-0.61)는 25°C 이하 구간의 기울기로, 온도가 낮을수록 난방 수요가 증가함을 나타낸다. Temp2 계수(+4.28)는 25°C 초과 구간의 **추가** 기울기로, 난방 수요가 급격히 증가함을 의미한다. PDQ(0,0,0)으로 계절 ARIMA 항은 제외하고 비계절 ARIMA 구조만 자동 탐색한다.

```
elec_fit |>
  gg_tsresiduals() +
  labs(title = "Residuals: Piecewise Linear Temp + ARIMA (Electricity)")
```



잔차 ACF에서 lag 7 부근에 유의한 스파이크가 관찰되어 주간(7일) 계절성이 일부 남아 있을 수 있다. 전반적인 잔차 분포는 정규분포에 가까우며, 대부분의 lag에서 자기상관이 제거되었다.


최적 Knot 위치 탐색

```
# compare AICc across knot candidates
knots <- seq(18, 32, by = 1)

aic_vals <- map_dbl(knots, function(k) { 각 knot 후보값 k에 대해 모델을 반복 적합하고
  vic_elec_daily |>                               AICc를 수집. map_dbl은 결과를 숫자 벡터로 반환
    mutate(TempK = I(pmax(Temperature - k, 0))) |>
    model(ARIMA(Demand ~ Temperature + TempK + Day_Type + PDQ(0,0,0))) |>
    glance() |> sknuc()로 모형 적합 요약 통계 추출 후 AICc 값만 저장
    pull(AICc)
})

knot_result <- tibble(knot = knots, AICc = aic_vals)

knot_result |>
  ggplot(aes(x = knot, y = AICc)) +
  geom_line() +
  geom_point() +
  geom_vline(xintercept = knots[which.min(aic_vals)],
             linetype = "dashed", colour = "red") +
  labs(title = "AICc by Knot Position (°C)",
       x = "Knot (°C)", y = "AICc")
```



```
cat("Best knot:", knots[which.min(aic_vals)], "deg C\n")
```

```
## Best knot: 22 deg C
```

```
cat("Min AICc:", min(aic_vals), "\n")
```

```
## Min AICc: 2548.002
```

AICc가 최소인 knot 위치(22°C)가 최적이다. 빨간 점선이 선택된 최적 knot를 표시한다. 이는 처음 가정한 25°C보다 낮은 온도에서 이미 냉방 수요가 증가하기 시작함을 의미하며, 빅토리아주의 기후 특성상 22°C부터 에어컨 가동이 본격화되는 것으로 해석할 수 있다.

최적 Knot로 예측

```
best_knot <- knots[which.min(aic_vals)]
```

```
# refit with optimal knot
```

```
elec_fit_best <- vic_elec_daily |>
```

```
  mutate(Temp2_best = I(pmax(Temperature - best_knot, 0))) |>
```

```
  model(
```

```
    ARIMA(Demand ~ Temperature + Temp2_best + Day_Type + PDQ(0,0,0))
```

```
)
```

```
# 14-day forecast from end of 2014
```

```
future_elec <- new_data(vic_elec_daily |>
```

```
  mutate(Temp2_best = I(pmax(Temperature - best_knot,
```




```

n = 14) |>
mutate(
  Temperature = 20, # assumed value
  Temp2_best = I(pmax(Temperature - best_knot, 0)),
  Day_Type = factor( # 원 데이터의 factor 수준과 동일하게 맞추어야 대버 (correct) 함
    case_when( # 정상 상태 등. 수준이 1이면 0과 2로 변경
      wday(Date) %in% 2:6 ~ "Weekday",
      TRUE ~ "Weekend"
    ),
    levels = c("Holiday", "Weekday", "Weekend") # same levels as training
  )
)

elec_fc <- forecast(elec_fit_best, new_data = future_elec)

elec_fc |>
autoplot(vic_elec_daily |>
  mutate(Temp2_best = I(pmax(Temperature - best_knot, 0))) |>
  tail(60)) +
labs(title = paste0("14-Day Electricity Forecast (Knot = ", best_knot, "°C)",
  y = "Demand (GWh)")

```




예측 기간의 기온을 20°C로 고정 가정하였기 때문에, 예측 수요 수준(약 150~200 GWh)이 실제 훈련 데이터의 평균 수준(약 200~350 GWh)보다 낮게 나타난다. 실제 예측 시에는 미래 기온 예보값을 사용하는 것이 바람직하다. 예측 구간은 시간이 지날수록 넓어지며 모형의 불확실성을 반영한다.

연습문제 5 — 미국 휘발유: 조화 회귀 + ARIMA 오차

문제: us_gasoline 전체 시계열에 대해 (a) TSLM으로 구간선형 추세 + Fourier 항 적합, (b) ARIMA로 재적합, (c) 잔차 진단, (d) 1년 예측.

(a) TSLM — 조화 회귀 + 구간선형 추세

```
us_gasoline |>
  autoplot(Barrels) +
  labs(title = "US Weekly Gasoline Consumption",
        y = "Million Barrels per Day")
```



```
# select K and knot position by AICc
# search K from 1 to 6 (period = 52 weeks)
K_vals <- 1:6

cv_tslm <- map_dfr(K_vals, function(k) {
  fit <- us_gasoline |>
    model(
      TSLM(Barrels ~ trend() + I(pmax(as.numeric(Week) - 500, 0)) +
        fourier(K = k))
    )
  glance(fit) |> mutate(K = k)
})

cv_tslm |>
  select(K, AICc, CV) |>
  arrange(AICc)
```

week 500 이후 추가 지수 변화를 모형화하는 구간선형 항,
 fourier(K = k) 주기 52주의 계절성은 k개의 sin/cos 항으로 관. k가 클수록 복잡한 패턴 포착하기엔 과적합 위험
 as.numeric은 week 변수를 숫자로 변환

```
## # A tibble: 6 x 3
##       K    AICc    CV
##   <int> <dbl> <dbl>
## 1     6 -2325. 0.180
## 2     5 -2318. 0.180
## 3     4 -2318. 0.180
## 4     3 -2314. 0.181
## 5     2 -2286. 0.185
## 6     1 -2280. 0.186
```

```
best_K <- cv_tslm$K[which.min(cv_tslm$AICc)]
cat("Best K:", best_K, "\n")
```

```
## Best K: 6
```

```
gas_tslm <- us_gasoline |>
  model(
    TSLM(Barrels ~ trend() + I(pmax(as.numeric(Week) - 500, 0)) +
      fourier(K = best_K))
  )
report(gas_tslm)
```

```
## Series: Barrels
## Model: TSLM
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12096 -0.30790  0.01868  0.33547  0.98496
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)              7.580e+00  2.293e-
02 330.614 < 2e-16 ***
## trend()              1.438e-03  2.929e-
05 49.081 < 2e-16 ***
## I(pmax(as.numeric(Week) - 500, 0))      NA      NA      NA      NA
## fourier(K = best_K)C1_52 -1.133e-01  1.621e-02  -
6.986 4.43e-12 ***
## fourier(K = best_K)S1_52 -2.316e-01  1.618e-02  -
14.309 < 2e-16 ***
## fourier(K = best_K)C2_52      4.317e-02  1.619e-
02 2.666 0.00778 *
## fourier(K = best_K)S2_52      3.018e-02  1.620e-
02 1.863 0.06266 .
## fourier(K = best_K)C3_52      8.496e-02  1.619e-
02 5.249 1.78e-07 ***
## fourier(K = best_K)S3_52      3.523e-02  1.620e-
02 2.174 0.02985 *
## fourier(K = best_K)C4_52      1.846e-02  1.621e-
02 1.139 0.25482
## fourier(K = best_K)S4_52      4.158e-02  1.618e-
02 2.569 0.01030 *
```

```
## fourier(K = best_K)C5_52          -3.309e-02  1.619e-02  -
2.044  0.04111 *
## fourier(K = best_K)S5_52          1.466e-03  1.620e-
02  0.090  0.92793
## fourier(K = best_K)C6_52          -5.319e-02  1.620e-02  -
3.284  0.00105 **
## fourier(K = best_K)S6_52          -1.174e-03  1.619e-02  -
0.072  0.94222
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4215 on 1341 degrees of freedom
## Multiple R-squared: 0.6708, Adjusted R-squared: 0.6676
## F-statistic: 210.2 on 13 and 1341 DF, p-value: < 2.22e-16
```

fourier(K = best_K)는 주기 52주의 계절성을 K쌍의 sin/cos 항으로 근사한다. K가 클수록 복잡한 계절 패턴을 포착하지만 과적합 위험이 있어, AICc로 최적 K를 선택한다.

report() 출력에서 구간선형 항 I(pmax(Week-500, 0))의 계수가 NA로 나타나는데, 이는 trend()와의 **완전 다중공선성(perfect collinearity)** 때문이다. trend()가 이미 선형 추세 전체를 설명하므로, TSLM에서는 구간선형 추가 기울기 항이 중복되어 제거된다. 다음 단계에서 ARIMA로 재적합하면 이 항이 정상적으로 추정된다.

(b) ARIMA로 재적합 (동일한 외생변수 유지)

```
gas_arima <- us_gasoline |>
  model(
    ARIMA(Barrels ~ trend() + I(pmax(as.numeric(Week) - 500, 0)) +
      fourier(K = best_K) + PDQ(0, 0, 0))
  )
report(gas_arima)
```

계단 ARIMA 제외, 비계단 ARIMA만 자동 추정
Fourier 항이 이미 계절성을 설명하므로 중복 방지.


```
## Series: Barrels
## Model: LM w/ ARIMA(0,0,5) errors
##
## Coefficients:
##          ma1          ma2          ma3          ma4          ma5 trend()
##          0.3924  0.3785  0.3584  0.3192  0.1735 -0.0112
## s.e.       0.0277  0.0288  0.0250  0.0249  0.0253  0.0001
##          I(pmax(as.numeric(Week) - 500, 0)) fourier(K = best_K)C1_52
##                                     0.0126 -0.1141
## s.e.                                0.0001  0.0291
##          fourier(K = best_K)S1_52 fourier(K = best_K)C2_52
##                                     -0.2363  0.0467
## s.e.                                0.0290  0.0273
##          fourier(K = best_K)S2_52 fourier(K = best_K)C3_52
##                                     0.0290  0.0856
## s.e.                                0.0273  0.0245
##          fourier(K = best_K)S3_52 fourier(K = best_K)C4_52
##                                     0.0377  0.0166
## s.e.                                0.0245  0.0210
```

```
##          fourier(K = best_K)S4_52    fourier(K = best_K)C5_52
##                                0.0414    -0.0322
## s.e.          0.0210          0.0170
##          fourier(K = best_K)S5_52    fourier(K = best_K)C6_52
##                                -0.0003    -0.0509
## s.e.          0.0170          0.0129
##          fourier(K = best_K)S6_52
##                                0.0002
## s.e.          0.0130
##
## sigma^2 estimated as 0.08794:  log likelihood=-266.37
## AIC=572.75   AICc=573.38   BIC=676.98
```

ARIMA() 로 재적합하면 TSLM과 동일한 외생변수를 유지하면서 잔차의 ARMA 구조를 자동으로 추정한다. TSLM에서 NA였던 구간선형 추세 항의 계수(+0.013)도 이제 정상적으로 추정된다. 선택된 모형은 MA(5) 오차 구조로, 5기간 전까지의 충격이 현재 값에 영향을 미친다.

(c) 잔차 진단

```
gas_arima |>
  gg_tsresiduals(lag_max = 52) +
  labs(title = "Residuals: Harmonic Regression + ARIMA (US Gasoline)")
```



```
augment(gas_arima) |>
  features(.innov, ljung_box, lag = 52, dof = best_K * 2 + 2)
```

```
## # A tibble: 1 x 3
```


```
##      .model                                lb_stat lb_pvalue
##      <chr>                                <dbl>   <dbl>
##      1  "ARIMA(Barrels ~ trend() + I(pmax(as.numeric(Week) -
500, 0~ 2449.                                0
```

Ljung-Box 검정 결과 p-value = 0으로, 유의수준 0.05에서 잔차에 **유의한 자기상관이 여전히 존재**한다는 결론을 내린다. ACF 플롯에서도 대부분의 lag에서 유의한 자기상관이 관찰된다. 이는 현재 MA(5) 오차 구조와 K=6 Fourier 항만으로는 휘발유 소비의 복잡한 주간 패턴을 완전히 설명하지 못함을 시사한다. PDQ 제약을 완화하거나 K를 추가로 조정하면 모형 개선이 가능하다.

(d) 향후 1년(52주) 예측

```
gas_fc <- gas_arima |>
  forecast(h = 52)

gas_fc |>
  autoplot(us_gasoline |> tail(156)) +
  labs(title = "US Gasoline: 52-Week Forecast (Harmonic Regression + ARIMA)",
        y = "Million Barrels per Day",
        x = "Week")
```



```
gas_fc |>
  as_tibble() |>
  select(Week, .mean) |>
  summarise(
    Forecast_Mean_Min = min(.mean),
    Forecast_Mean_Max = max(.mean),
```

```
Forecast_Mean_Avg = mean(.mean)
)
```

```
## # A tibble: 1 x 3
##   Forecast_Mean_Min Forecast_Mean_Max Forecast_Mean_Avg
##           <dbl>           <dbl>           <dbl>
## 1           8.37           9.89           9.51
```

예측값은 계절 패턴을 반영하여 여름철 소비 증가와 겨울철 감소를 포착한다. ARIMA 오차 구조 덕분에 단순 TSLM 대비 단기 예측 정확도가 향상된다. 다만 Ljung-Box 검정에서 잔차의 자기상관이 완전히 제거되지 않았으므로, 예측 구간의 신뢰성에는 한계가 있다.
