

PBS 데이터 계층적 시계열 예측 분석

2176071 김수민

2026-05-22

Contents

1	서론	2
2	데이터 탐색	2
2.1	PBS 데이터 로드 및 구조 확인	2
2.2	계층 구조 정의	3
3	탐색적 데이터 분석 (EDA)	3
3.1	Concession별 Scripts 집계 시각화	3
3.2	Type별 Scripts 집계 시각화	5
3.3	ATC1별 Scripts 집계 시각화	6
4	예측 모델링	7
4.1	훈련/테스트 데이터 분할	7
4.2	예측 모델 적합	8
5	예측 조화 (Reconciliation)	8
5.1	MinT(Minimum Trace) 조정법	8
5.2	예측 생성 및 조화	9
5.3	집계 수준에서의 예측 시각화	9
6	예측 정확도 평가	10
6.1	정확도 지표 계산	10
6.2	모델별 평균 정확도 비교	11
6.3	조화 전후 RMSSE 비교 (박스플롯)	11
7	결과 해석 및 논의	13
7.1	어떤 모델이 가장 우수한가?	13
7.2	조화가 예측 정확도를 개선하는가?	13
7.3	SNAIVE 조화가 효과가 없는 이유	14

1 서론

본 분석은 호주 약품 급여 제도(Pharmaceutical Benefits Scheme, PBS) 데이터를 활용하여 계층적 시계열 예측(Hierarchical Time Series Forecasting)을 수행합니다.

PBS 데이터는 다음과 같은 집계 구조를 가집니다:

$$\text{ATC1/ATC2} \times \text{Concession} \times \text{Type}$$

본 보고서에서는 다음을 순서대로 다룹니다:

1. Concession, Type, ATC1별 집계 데이터 시각화
2. ETS, ARIMA, SNAIVE 모델을 이용한 예측 (마지막 3년 제외)
3. MinT(Minimum Trace) 조정법을 이용한 예측 조화(Reconciliation)
4. 테스트 셋에서의 모델 성능 비교
5. 조화가 예측 정확도에 미치는 영향 분석
6. SNAIVE 예측에 조화가 차이를 만들지 못하는 이유 설명

2 데이터 탐색

2.1 PBS 데이터 로드 및 구조 확인

```
data("PBS")
glimpse(PBS)
```

```
## Rows: 67,596
## Columns: 9
## Key: Concession, Type, ATC1, ATC2 [336]
## $ Month      <mtch> 1991 Jul, 1991 Aug, 1991 Sep, 1991 Oct, 1991 Nov, 1991 Dec,~
## $ Concession <chr> "Concessional", "Concessional", "Concessional", "Concession~
## $ Type       <chr> "Co-payments", "Co-payments", "Co-payments", "Co-payments",~
## $ ATC1       <chr> "A", "A", "A", "A", "A", "A", "A", "A", "A", "A", "A",~
## $ ATC1_desc  <chr> "Alimentary tract and metabolism", "Alimentary tract and me~
## $ ATC2       <chr> "A01", "A01", "A01", "A01", "A01", "A01", "A01", "A01", "A0~
## $ ATC2_desc  <chr> "STOMATOLOGICAL PREPARATIONS", "STOMATOLOGICAL PREPARATIONS~
## $ Scripts    <dbl> 18228, 15327, 14775, 15380, 14371, 15028, 11040, 15165, 168~
## $ Cost       <dbl> 67877.00, 57011.00, 55020.00, 57222.00, 52120.00, 54299.00,~
```

```
cat("관측치 수:", nrow(PBS), "\n")
```

```
## 관측치 수: 67596
```

```
cat("시작 시점:", as.character(min(PBS$Month)), "\n")
```

```
## 시작 시점: 1991 Jul
```

```
cat("종료 시점:", as.character(max(PBS$Month)), "\n")
```

```
## 종료 시점: 2008 Jun
```

```
cat("ATC1 수준:", n_distinct(PBS$ATC1), "\n")
```

```
## ATC1 수준: 15
```

```
cat("ATC2 수준:", n_distinct(PBS$ATC2), "\n")
```

```
## ATC2 수준: 84
```

```
cat("Concession 수준:", n_distinct(PBS$Concession), "\n")
```

```
## Concession 수준: 2
```

```
cat("Type 수준:", n_distinct(PBS$Type), "\n")
```

```
## Type 수준: 2
```

PBS 데이터는 월별 시계열로 구성되어 있으며, 집계 구조는 다음과 같습니다:

- **ATC1**: 약물 분류 대분류 (7개 수준)
- **ATC2**: 약물 분류 소분류 (ATC1의 하위 분류)
- **Concession**: 수급 자격 (Concessional / General)
- **Type**: 처방 유형 (Co-payments / Safety net)

2.2 계층 구조 정의

```
PBS_aggregated <- PBS |>
  aggregate_key(
    ATC1 / ATC2 * Concession * Type,
    Scripts = sum(Scripts),
    Cost     = sum(Cost)
  )
```

3 탐색적 데이터 분석 (EDA)

3.1 Concession별 Scripts 집계 시각화

```
PBS_aggregated |>
  filter(
    is_aggregated(ATC1),
    is_aggregated(ATC2),
    !is_aggregated(Concession),
    is_aggregated(Type)
  ) |>
  autoplot(Scripts) +
  facet_wrap(~ as.character(Concession), scales = "free_y", ncol = 1) +
  labs(
    title = "Concession 유형별 월별 처방 건수",
    x     = "연월",
    y     = "처방 건수"
  ) +
  theme_bw(base_size = 12) +
  theme(legend.position = "none")
```




Figure 1: Concession 유형별 월별 처방 건수 추이

해석: Concessional(수급자) 처방 건수는 General(일반) 처방 건수보다 훨씬 높으며, 두 유형 모두 뚜렷한 계절성 패턴을 보입니다. Concessional 건수는 시간에 따라 점진적 감소 추세가 관찰됩니다.

3.2 Type별 Scripts 집계 시각화

```
PBS_aggregated |>
  filter(
    is_aggregated(ATC1),
    is_aggregated(ATC2),
    is_aggregated(Concession),
    !is_aggregated(Type)
  ) |>
  autoplot(Scripts) +
  facet_wrap(~ as.character(Type), scales = "free_y", ncol = 1) +
  labs(
    title = "처방 유형(Type)별 월별 처방 건수",
    x      = "연월",
    y      = "처방 건수"
  ) +
  theme_bw(base_size = 12) +
  theme(legend.position = "none")
```




Figure 2: 처방 유형별 월별 처방 건수 추이

해석: Co-payments(공동 부담) 유형이 Safety net(안전망) 유형보다 처방 건수가 현저히 높습니다. Safety net 유형은 계절성이 더욱 두드러지며, 연말에 급격한 증가 패턴이 나타납니다.

3.3 ATC1별 Scripts 집계 시각화

```
PBS_aggregated |>
  filter(
    !is_aggregated(ATC1),
    is_aggregated(ATC2),
    is_aggregated(Concession),
    is_aggregated(Type)
  ) |>
  autoplot(Scripts) +
  facet_wrap(~ as.character(ATC1), scales = "free_y") +
  labs(
    title = "ATC1 약물 분류별 월별 처방 건수",
    x      = "연월",
    y      = "처방 건수"
  ) +
  theme_bw(base_size = 10) +
  theme(legend.position = "none")
```




Figure 3: ATC1 약물 분류별 월별 처방 건수 추이

해석: ATC1 분류에 따라 처방 건수의 규모와 패턴이 크게 다릅니다. 일부 분류는 완만한 증가 추세를 보이는 반면, 뚜렷한 계절적 변동이 관찰되는 분류도 존재합니다.

4 예측 모델링

4.1 훈련/테스트 데이터 분할

마지막 3년(36개월)을 테스트 셋으로 분리합니다.

```
test_horizon <- 36

max_date <- max(PBS_aggregated$Month)
train_end <- max_date - test_horizon

cat("전체 데이터 기간:", as.character(min(PBS_aggregated$Month)),
    "~", as.character(max_date), "\n")
```

전체 데이터 기간: 1991 Jul ~ 2008 Jun

```
cat("훈련 데이터 종료:", as.character(train_end), "\n")
```

훈련 데이터 종료: 2005 Jun

```
cat("테스트 데이터 기간:", as.character(train_end + 1),
    "~", as.character(max_date), "\n")
```

테스트 데이터 기간: 2005 Jul ~ 2008 Jun

```
PBS_train <- PBS_aggregated |> filter(Month <= train_end)
PBS_test <- PBS_aggregated |> filter(Month > train_end)
```

4.2 예측 모델 적합

세 가지 모델을 훈련 데이터에 적합합니다:

- **ETS**: 지수 평활 상태 공간 모델
- **ARIMA**: 자기회귀 누적 이동평균 모델 (자동 선택)
- **SNAIVE**: 계절적 순진 예측 모델

```
PBS_fit <- PBS_train |>
  model(
    ets = ETS(Scripts),
    arima = ARIMA(Scripts),
    snaive = SNAIVE(Scripts)
  )

cat("적합된 시계열 수:", nrow(PBS_fit), "\n")
```

적합된 시계열 수: 900

5 예측 조화 (Reconciliation)

5.1 MinT(Minimum Trace) 조정법

MinT 방법은 계층적 시계열 예측의 조화 기법으로, 예측값들이 계층 구조의 집계 제약 조건을 만족하도록 조정합니다. 조화된 예측의 오차 공분산 행렬의 trace를 최소화하는 방식으로 조정 행렬 G 를 추정합니다:

$$\tilde{\mathbf{y}}_T = SG\hat{\mathbf{y}}_T$$

여기서 S 는 합산 행렬(Summing matrix), $\hat{\mathbf{y}}_T$ 는 기저 예측값, $\tilde{\mathbf{y}}_T$ 는 조화된 예측값입니다.

본 분석에서는 `ols` 방법을 적용합니다. PBS 데이터는 일부 하위 시계열(Safety net 계열 등)에 결측값 또는 0값이 포함되어 공분산 행렬이 singular해지므로, 공분산 추정 없이 `ols`가 유일하게 안정적으로 작동합니다.

5.2 예측 생성 및 조화

```
# reconcile()로 조화 모델을 먼저 정의한 뒤 forecast() 호출
PBS_fc <- PBS_fit |>
  reconcile(
    ets_mint = min_trace(ets, method = "ols"),
    arima_mint = min_trace(arima, method = "ols"),
    snaive_mint = min_trace(snaive, method = "ols")
  ) |>
  forecast(h = test_horizon)

cat("예측 생성 완료\n")
```

```
## 예측 생성 완료
```

5.3 집계 수준에서의 예측 시각화

```
PBS_fc |>
  filter(
    is_aggregated(ATC1),
    is_aggregated(ATC2),
    is_aggregated(Concession),
    is_aggregated(Type)
  ) |>
  autoplot(
    PBS_aggregated |> filter(Month > yearmonth("2003 Jan")),
    level = NULL
  ) +
  labs(
    title = "전체 집계 수준 - 모델별 처방 건수 예측",
    x = "연월",
    y = "처방 건수",
    colour = "모델"
  ) +
  theme_bw(base_size = 11) +
  theme(legend.position = "bottom")
```




Figure 4: 전체 집계 수준에서의 모델별 예측 비교

6 예측 정확도 평가

6.1 정확도 지표 계산

MAPE는 실제값이 0인 시계열에서 무한대가 되므로, RMSSE와 MASE만 사용합니다.

```
accuracy_results <- PBS_fc |>
  accuracy(
    data      = PBS_aggregated,
    measures = list(RMSSE = RMSSE, MASE = MASE)
  )
```

```
accuracy_results
```

```
## # A tibble: 5,400 x 8
##   .model ATC1 Concession Type      ATC2 .type RMSSE MASE
##   <chr> <chr*> <chr*>    <chr*>    <chr*> <chr> <dbl> <dbl>
## 1 arima A      Concessional Co-payments A01 Test 0.926 0.969
## 2 arima A      Concessional Co-payments A02 Test 1.34 1.30
```

```
## 3 arima A Concessional Co-payments A03 Test 1.91 2.49
## 4 arima A Concessional Co-payments A04 Test 1.23 1.38
## 5 arima A Concessional Co-payments A05 Test 0.449 0.478
## 6 arima A Concessional Co-payments A06 Test 1.14 1.19
## 7 arima A Concessional Co-payments A07 Test 1.16 1.19
## 8 arima A Concessional Co-payments A09 Test 2.56 2.76
## 9 arima A Concessional Co-payments A10 Test 1.49 1.47
## 10 arima A Concessional Co-payments A11 Test 0.557 0.544
## # i 5,390 more rows
```

6.2 모델별 평균 정확도 비교

```
acc_summary <- accuracy_results |>
  filter(!is.infinite(RMSSE), !is.infinite(MASE)) |>
  group_by(.model) |>
  summarise(
    평균_RMSSE = mean(RMSSE, na.rm = TRUE),
    평균_MASE = mean(MASE, na.rm = TRUE),
    .groups = "drop"
  ) |>
  arrange(평균_RMSSE) |>
  rename(모델 = .model)

kable(
  acc_summary,
  caption = "모델별 평균 예측 정확도 (낮을수록 좋음)",
  digits = 4,
  booktabs = TRUE
) |>
  kable_styling(
    latex_options = c("striped", "hold_position"),
    full_width = FALSE
  ) |>
  row_spec(1, bold = TRUE, background = "#d4edda")
```

Table 1: 모델별 평균 예측 정확도 (낮을수록 좋음)

모델	균_RMSSE 평균	MASE
arima	2.3004	2.2137
ets	2.3233	2.3404
snaive	2.3916	2.2954
snaive_mint	2.3916	2.2954
arima_mint	67.0388	166.6191
ets_mint	104.9340	252.1944

6.3 조화 전후 RMSSE 비교 (박스플롯)

```

acc_plot <- accuracy_results |>
  filter(!is.na(RMSSE), !is.infinite(RMSSE)) |>
  mutate(
    base_model = case_when(
      .model %in% c("ets", "ets_mint") ~ "ETS",
      .model %in% c("arima", "arima_mint") ~ "ARIMA",
      .model %in% c("snaive", "snaive_mint") ~ "SNAIVE"
    ),
    reconciled = ifelse(grepl("_mint", .model), "조화 후 (MinT)", "조화 전 (기저)")
  )

acc_plot |>
  ggplot(aes(x = base_model, y = RMSSE, fill = reconciled)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.3) +
  scale_fill_manual(
    values = c("조화 전 (기저)" = "#4472C4", "조화 후 (MinT)" = "#ED7D31")
  ) +
  coord_cartesian(ylim = c(0, quantile(acc_plot$RMSSE, 0.95))) +
  labs(
    title = "모델별 RMSSE 분포: 조화 전 vs 조화 후",
    x = "모델",
    y = "RMSSE (낮을수록 좋음)",
    fill = "조화 여부"
  ) +
  theme_bw(base_size = 12) +
  theme(legend.position = "bottom")

```




Figure 5: 조화 전후 모델별 RMSSE 분포 비교

7 결과 해석 및 논의

7.1 어떤 모델이 가장 우수한가?

```
best_model <- acc_summary |> slice(1) |> pull(모델)
cat("테스트 셋 기준 최우수 모델:", best_model, "\n")
```

테스트 셋 기준 최우수 모델: arima

분석 결과:

테스트 셋 기준 최우수 모델은 **ARIMA**(평균 RMSSE 2.30)이며, ETS(2.32), SNAIVE(2.39) 순입니다. 세 모델의 차이는 크지 않으나, ARIMA가 PBS 데이터의 자기상관 구조를 효과적으로 포착하여 소폭 우위를 보였습니다. SNAIVE는 단순한 계절적 참조 모델임에도 ETS, ARIMA와 큰 차이 없이 선전했는데, 이는 PBS 처방 건수가 강한 계절성을 가지기 때문입니다.

7.2 조화가 예측 정확도를 개선하는가?

```
# 기저 모델과 MinT 모델 RMSSE 비교
base_rmsse <- acc_summary |>
  filter(!grepl("_mint", 모델)) |>
  mutate(모델_키=toupper(모델)) |>
  select(모델_키, 기저_RMSSE = 평균_RMSSE)

mint_rmsse <- acc_summary |>
  filter(grepl("_mint", 모델)) |>
  mutate(모델_키=toupper(gsub("_mint", "", 모델))) |>
  select(모델_키, MinT_RMSSE = 평균_RMSSE)

reconcile_comparison <- base_rmsse |>
  left_join(mint_rmsse, by = "모델_키") |>
  mutate(
    개선율_pct = round((기저_RMSSE - MinT_RMSSE) / 기저_RMSSE * 100, 2),
    개선_여부 = ifelse(개선율_pct > 0, "개선됨", "미개선")
  ) |>
  rename(모델 = 모델_키)

kable(
  reconcile_comparison,
  caption = "MinT 조화 전후 RMSSE 비교 및 개선율",
  digits = 4,
  booktabs = TRUE
) |>
  kable_styling(latex_options = c("striped", "hold_position")) |>
  column_spec(4, bold = TRUE)
```

Table 2: MinT 조화 전후 RMSSE 비교 및 개선율

모델	기저_RMSSE	MinT_RMSSE	개선율_pct	개선_여부
ARIMA	2.3004	67.0388	-2814.16	미개선
ETS	2.3233	104.9340	-4416.63	미개선
SNAIVE	2.3916	2.3916	0.00	미개선

결론:

이 데이터에서 ols 기반 MinT 조화는 **ETS와 ARIMA의 예측 정확도를 오히려 크게 악화시켰습니다** (ARIMA: 2.30 → 67.04, ETS: 2.32 → 104.93). 이는 ols 방법의 구조적 한계에서 비롯됩니다.

ols MinT는 공분산 행렬 추정 없이 단순 최소제곱으로 조정 행렬 G 를 구하기 때문에, Safety net처럼 값이 0에 가깝거나 분산이 매우 작은 하위 시계열이 다수 포함된 경우 음수 예측값이 발생할 수 있습니다. 처방 건수(Scripts)는 음수가 불가능한 변수이므로, 음수 예측값이 생긴 시계열의 RMSSE는 극단적으로 커지고 이것이 전체 평균을 왜곡합니다.

MinT가 이론적으로 효과를 발휘하려면 공분산 구조를 제대로 추정할 수 있어야 합니다. wls_var나 mint_shr 같은 방법이 더 적합하지만, PBS 데이터는 시계열 수(900개)에 비해 관측 기간이 짧고 0값 시계열이 많아 이 방법들도 공분산 행렬이 singular해지는 문제가 발생합니다. 결과적으로 이 데이터에서는 ols MinT가 유일하게 실행 가능한 옵션이지만, 그 결과는 기저 예측보다 나쁩니다.

7.3 SNAIVE 조화가 효과가 없는 이유

SNAIVE(Seasonal Naive) 모델은 지난 해 같은 달의 실제 관측값을 그대로 사용하는 예측 방법입니다:

$$\hat{y}_{T+h|T} = y_{T+h-m}, \quad m = 12$$

MinT 조화가 SNAIVE에 효과가 없는 핵심 이유는 **SNAIVE 예측이 이미 집계 일관성(coherence)을 만족하기** 때문입니다.

실제 관측값은 계층 구조를 당연히 만족합니다. 즉,

$$y_t^{\text{total}} = \sum_j y_t^j$$

SNAIVE는 이 실제값을 그대로 복사하므로, 기저 예측 자체가 이미 다음을 만족합니다:

$$\hat{y}_{T+h}^{\text{total}} = y_{T+h-12}^{\text{total}} = \sum_j y_{T+h-12}^j = \sum_j \hat{y}_{T+h}^j$$

따라서 MinT 조화 행렬 G 를 적용해도 조화 후 값이 조화 전 값과 동일합니다:

$$\tilde{y} = SG\hat{y} = \hat{y}$$

이는 SNAIVE의 단점이 아니라 구조적 특성입니다. 반면 ETS나 ARIMA는 각 시계열을 독립적으로 최적화하므로 집계 불일치가 발생하고, MinT 조화의 효과가 나타납니다.

8 요약 및 결론

항목	결론
최우수 기저 모델	ARIMA (평균 RMSSE 2.30)
조화 효과 (ETS, ARIMA)	없음 — ols MinT가 오히려 정확도 악화
SNAIVE 조화 효과	없음 — 이미 집계 일관성 만족
권장 모델	기저 ARIMA 또는 ETS

핵심 발견사항:

1. 기저 모델 중에서는 ARIMA가 가장 우수하며, ETS, SNAIVE 순으로 성능 차이가 크지 않습니다. PBS 처방 건수의 강한 계절성 덕분에 SNAIVE도 나쁘지 않은 성능을 보입니다.
2. ols MinT 조화는 이 데이터에서 예측 정확도를 개선하지 못했습니다. Safety net 등 0값이 많은 하위 시계열에서 음수 예측값이 발생하고, 이로 인해 RMSSE가 극단적으로 커졌기 때문입니다. MinT가 효과를 내려면 공분산 행렬이 안정적으로 추정돼야 하는데, 이 데이터는 그 조건을 만족하지 못합니다.
3. SNAIVE 예측은 실제 관측값의 직접 복사이므로 집계 구조를 자동으로 만족합니다. MinT 조화를 적용해도 예측값이 변하지 않으며, 이는 모델의 한계가 아닌 구조적 특성입니다.